

Intelligence Artificielle & Machine Learning

Une vue d'ensemble des concepts fondamentaux, des paradigmes d'apprentissage et de l'évaluation des modèles.

1. Introduction aux Concepts Clés

Le domaine de l'Intelligence Artificielle (IA) englobe un vaste spectre de technologies visant à doter les machines de capacités cognitives humaines. Pour bien comprendre ce domaine, il est crucial de distinguer trois strates fondamentales qui s'imbriquent les unes dans les autres.




Figure 1 : Hiérarchie des domaines de l'Intelligence Artificielle.

Intelligence Artificielle (IA) : Le domaine global consistant à créer des machines capables de simuler l'intelligence humaine (raisonnement, perception, prise de décision).

Machine Learning (ML) : Un sous-domaine de l'IA. Au lieu d'être explicitement programmées, les machines utilisent des algorithmes pour *apprendre* à partir de données afin d'améliorer leurs performances sur une tâche spécifique.

Deep Learning (DL) : Une technique spécifique de Machine Learning basée sur des *réseaux de neurones artificiels* à plusieurs couches, particulièrement efficace pour les images, le texte et le son.

La donnée, carburant de l'IA

Le Machine Learning repose intégralement sur les données (Data). Un modèle n'est que le reflet

2. Les Paradigmes du Machine Learning

Les algorithmes d'apprentissage automatique se divisent en trois grandes familles, selon la nature des données fournies (étiquetées ou non) et le type de retour (feedback) que l'algorithme reçoit lors de son entraînement.

1. Apprentissage Supervisé

Principe : L'algorithme apprend à partir de données *étiquetées* (la réponse correcte est connue). Il cherche à établir la relation entre l'entrée (X) et la sortie (Y).

Exemples : Classification (spam ou non), Régression (prédiction d'un prix).

2. Apprentissage Non-Supervisé

Principe : Les données n'ont *pas d'étiquettes*. L'algorithme doit trouver lui-même la structure sous-jacente ou les modèles cachés dans les données.

Exemples : Clustering (segmentation client), Réduction de dimensionnalité.

3. Apprentissage par Renforcement

Principe : Un "agent" interagit avec un environnement et apprend en recevant des *récompenses* ou des *pénalités* en fonction de ses actions.

Exemples : Conduite autonome, Jeux complexes (Échecs, Go), Robotique.

Focus sur le cycle de vie d'un modèle (Supervisé)

La création d'un modèle prédictif suit un processus standardisé. Les données sont généralement divisées en deux ensembles distincts pour éviter le surapprentissage (overfitting).




Figure 2 : Cycle d'entraînement et d'évaluation d'un modèle d'apprentissage supervisé.

L'Overfitting (Surapprentissage) : C'est l'écueil principal en Machine Learning. Le modèle "apprend par cœur" les données d'entraînement, y compris le bruit, et devient incapable de généraliser sur de nouvelles données. On le détecte lorsque la performance sur les données d'entraînement est excellente, mais très faible sur les données de test.

3. Deep Learning et Réseaux de Neurones

Le Deep Learning s'inspire du fonctionnement du cerveau humain. Il utilise des **réseaux de neurones artificiels** pour résoudre des problèmes très complexes (vision par ordinateur, traitement du langage naturel).




Figure 3 : Architecture basique d'un réseau de neurones multicouches.

Chaque "neurone" calcule une somme pondérée de ses entrées, puis applique une fonction mathématique (fonction d'activation) pour décider du signal à transmettre à la couche suivante.

4. Métriques d'Évaluation

Comment savoir si notre modèle est performant ? La simple exactitude (Accuracy) est souvent insuffisante, en particulier si les classes sont déséquilibrées (ex: détection d'une maladie rare). On utilise donc des métriques plus fines issues de la **Matrice de Confusion**.

Métrique	Signification	Cas d'usage idéal
Accuracy (Exactitude)	Proportion de prédictions correctes sur le total.	Classes parfaitement équilibrées.
Precision (Précision)	Parmi ce que le modèle a prédit comme "Positif", combien le sont réellement ?	Quand un Faux Positif coûte très cher (ex: Filtre Spam).
Recall (Rappel / Sensibilité)	Parmi tous les "Positifs" réels, combien le modèle a-t-il réussi à détecter ?	Quand un Faux Négatif est dangereux (ex: Diagnostic médical).
F1-Score	Moyenne harmonique entre Precision et Recall.	Recherche du meilleur compromis global.